Міністерство освіти і науки України
Національний технічний університет України «КПІ» імені Ігоря Сікорського Кафедра обчислювальної техніки ФІОТ

ЗВІТ
з лабораторної роботи №1
з навчальної дисципліни «Аналіз та обробка природної мови (NLP)»

Тема:

ОТРИМАННЯ І ПОПЕРЕДНЯ ФІЛЬТРАЦІЯ ПРИРОДНОЇ МОВИ

Виконав:
Студент 3 курсу кафедри ОТ ФІОТ, Навчальної групи ІО-31
Устимчик П.Я.
Перевірив:
Асистент кафедри ОТ ФІОТ
Баран Данило Романович

Київ 2026

І. Мета:
Дослідити процеси отримання та попередньої фільтрації повідомлень природною
мовою з використанням спеціалізованих пакетів / бібліотек python.
ІІ. Завдання:
Завдання І, рівня складності – максимально 8 балів.
Розробити скрипт мовою python з процесами та функціоналом:
1. Обрати джерело даних – природньої мови, наприклад інформаційна стрічка новин,
технічна документація, публіцистичні тексти, аналітичні статті, книги.
Увага!!! Інформаційний контент має бути поданий українською або англійською
мовами та мати коректний контент.
2. Провести парсинг / скрапінг даних обраного інформаційних джерел з отриманням
інформаційного контенту, поданого природньою мовою.
3. Провести попередню фільтрацію результатів парсингу / скрапінгу обраного
інформаційного джерела із фокусом на обраний контент.
Фільтрація має на меті прибрати все зайве, що захаращує чи змінює інформаційний
контент.
4. Результати фільтрації систематизувати залежно від структури інформаційного
контенту та зберегти у файлі. Тип файлу має відповідати структурі інформаційного
контенту.
5. Результатом є файл з обраним інформаційним контентом після фільтрації.
ІІІ. Результати виконання лабораторної роботи.
3.1 Синтезована математична модель
Синтезована математична модель в даній лабораторній роботі включає в себе 8 основних компонентів:

1. Формулювання задачі

Метою моделі є автоматизоване отримання текстових даних природної мови з новинного веб-ресурсу, їх структурний аналіз, очищення та збереження у формалізованому вигляді для подальшої обробки.

2. Формування HTTP-запиту

Процес починається з надсилання HTTP-запиту до обраного новинного сайту.У відповідь сервер повертає HTML-документ, що містить текстові дані та службову розмітку.Для реалізації запиту використано бібліотеку requests.

3. Отримання HTML-документа

Отриманий HTML-документ розглядається як структуроване дерево елементів (DOM-структура), що містить інформаційні блоки сторінки. Аналіз структури документа здійснюється за допомогою бібліотеки BeautifulSoup.

4. Виділення контейнерів новин

У HTML-структурі визначаються блоки, що відповідають окремим новинам (тег article). Кожен такий контейнер розглядається як окрема одиниця обробки.

5. Вилучення атрибутів новини

Із кожного контейнера послідовно витягуються:

- заголовок;
- посилання на матеріал;
- дата публікації;
- текст новини.

У разі відсутності стандартного елемента застосовується альтернативний пошук за тегами або CSS-класами.

6. Попередня фільтрація тексту

Отриманий текст очищується від:

- надлишкових пробілів;
- службових символів;
- порожніх рядків.

Для нормалізації використано регулярні вирази (re).
Операція очищення виконується за один прохід по тексту.

7. Формування структурованої моделі даних

Кожна новина представляється у вигляді словникового об’єкта з фіксованими полями:

- title

- date

- url

- text

Сукупність таких об’єктів формує масив структурованих даних.

8. Систематизація та збереження результатів

Після формування масиву дані зберігаються у форматі CSV.
Файл містить заголовки стовпців та послідовний запис кожної новини окремим рядком.

3.2. Результати архітектурного проектування та їх опис;

Архітектурна блок-схема системи

Архітектура системи побудована за модульним принципом.
Кожен модуль виконує окрему функцію обробки даних та передає результат наступному компоненту.

Опис архітектурної моделі

1. *Модуль HTTP-запиту*
Відповідає за отримання HTML-документа шляхом надсилання запиту до веб-ресурсу.

2. Модуль парсингу HTML
Аналізує структуру HTML-документа, знаходить контейнери новин та

витягує необхідні атрибути.

3.*Модуль очищення тексту*
Виконує попередню нормалізацію текстових даних.

4. *Модуль формування структури даних*
Перетворює отримані дані у структурований масив словників.

5. *Модуль збереження*
Записує сформований масив у CSV-файл.
Загальна блок-схема процесу функціонування системи

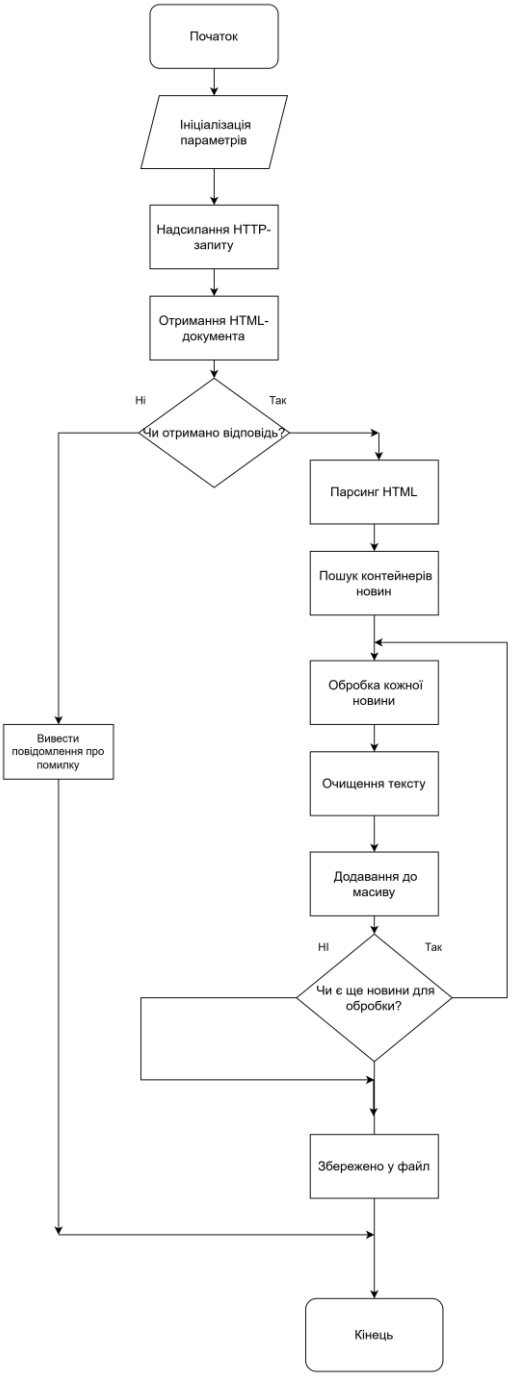

Опис блок-схеми алгоритму

Блок-схема відображає послідовність виконання операцій під час отримання та обробки текстових даних природної мови з веб-ресурсу. Алгоритм починається з ініціалізації параметрів та надсилання HTTP-запиту. Після перевірки отримання відповіді виконується парсинг HTML-документа та пошук контейнерів новин.

Далі реалізується цикл обробки кожної новини, що включає очищення тексту та додавання структурованих даних до масиву. Після завершення обробки всіх новин виконується збереження результатів у файл та завершення роботи програми.

3.3. Опис структури проекту програми:

main.py	17.02.2026 12:14	Python Source File	9 КБ
pravda_html.html	17.02.2026 12:19	Chrome HTML Docu...	706 КБ
pravda_news_20260217_122022.csv	17.02.2026 12:20	XLS Worksheet	17 КБ

Проєкт реалізовано у вигляді одного програмного файлу main.py, що містить повну логіку отримання, обробки та збереження текстових даних природної мови.

Структура каталогу проєкту включає:

- main.py — основний файл програми, який містить функції:
- формування HTTP-запиту;
- парсингу HTML-документа;
- очищення текстових даних;
- систематизації інформації;
- збереження результатів у форматі CSV;

pravda_html.html — збережений вихідний HTML-код веб-сторінки, використаний для аналізу DOM-структури та визначення інформаційних контейнерів новин;

pravda_news_дата_час.csv — файл результатів, що містить структуровані дані новин після фільтрації та систематизації.

Таким чином, структура проєкту забезпечує розділення програмної реалізації, аналізу структури веб-ресурсу та збережених результатів обробки даних.

3.4. Результати роботи програми відповідно до завдання:
При запуску програми маємо отаке вікно :

```
ПАРСИНГ PRAVDA.COM.UA

Доступні розділи:
1. Новини
2. Політика
3. Економіка
4. Європейська правда
5. Життя
6. Колонки

Виберіть 3 розділи (через кому, наприклад 1,2,3): 1,3,6
```

Тут слід обрати 3 розділи із запропонованих з яких будуть братись новини .
Коли розділи були обрані , починається виконання :

```
Обрані розділи:
• Новини
• Економіка
• Колонки

Завантаження розділу: Новини
Знайдено новин: 10

Завантаження розділу: Економіка
Знайдено новин: 10

Завантаження розділу: Колонки
Знайдено новин: 9

Всього зібрано: 29 новин
Збережено у файл: pravda_news_20260217_123452.csv

Готово!
```

Виводиться інформація про обрані розділи, кількість новин для кожного з обраного розділу та загальну кількість статей.Також виводиться повідомлення про збереження інформації у файл.

Вигляд самого файлу :

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
1	Розділ,Заголовок,Дата,Посилання,Опис																
2	Новини,Публікації,Дата не вказана,https://www.pravda.com.ua/articles/,"Естафета – одна з найцікавіших та найбільш непередбачуваних дисциплін в біатлоні, та й в інших циклічних видах спорту																
3	Новини,Офіс омбудсмана просить Раду прибрати заборону на поховання військових із судимістю на НВМК,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021416/,"Офіс військо																
4	Новини,"В Орбана знайшли лазівку, щоб загальмувати ухвалення 20-го пакету санкцій ЄС проти Росії – Politico",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021421/,"Видання																
5	Новини,"Переломи, травми, розтрощені авто киян: комунальники 9 районів столиці отримали підозри",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021414/,"П рокурори пов																
6	Новини,"Фото, аудіо ""Визволяв"" із ТЦК під приводом слідчих дій: судитимуть правоохоронця з Миколаївщини",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021412/,"ДБР за																
7	Новини,Колишнього міністра Нагірного Карабаху Варданяна засудили до 20 років в'язниці,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021413/,"Військовий суд у Баку засуди																
8	Новини,"Відео, фото Росія вбила дроном трьох працівників Слов'янської ТЕС",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021407/,"Російські окупаційні війська 17 лютого вда																
9	Новини,"відео ССО дронами FP-2 уразили місце зберігання ""Іскандерів"" в Криму",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021404/,"Підрозділи Сил спеціальних операці																
10	Новини,Росія почне повністю блокувати Telegram з 1 квітня – Baza,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021405/,"Telegram-каналу ""База"" повідомив, що в Росії почну																
11	Новини,"На КПП Польщі з Україною у мандрівника виявили гранату, людей евакуювали",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021400/,"На пункті пропуску в Долгобич																
12	Економіка,Публікації,Дата не вказана,https://www.pravda.com.ua/articles/,"Естафета – одна з найцікавіших та найбільш непередбачуваних дисциплін в біатлоні, та й в інших циклічних видах спо																
13	Економіка,Офіс омбудсмана просить Раду прибрати заборону на поховання військових із судимістю на НВМК,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021416/,"Офіс військ																
14	Економіка,"В Орбана знайшли лазівку, щоб загальмувати ухвалення 20-го пакету санкцій ЄС проти Росії – Politico",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021421/,"Видан																
15	Економіка,"Переломи, травми, розтрощені авто киян: комунальники 9 районів столиці отримали підозри",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021414/,"П рокурори п																
16	Економіка,"Фото, аудіо ""Визволяв"" із ТЦК під приводом слідчих дій: судитимуть правоохоронця з Миколаївщини",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021412/,"ДБР																
17	Економіка,Колишнього міністра Нагірного Карабаху Варданяна засудили до 20 років в'язниці,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021413/,"Військовий суд у Баку засу,																
18	Економіка,"Відео, фото Росія вбила дроном трьох працівників Слов'янської ТЕС",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021407/,"Російські окупаційні війська 17 лютого в																
19	Економіка,"відео ССО дронами FP-2 уразили місце зберігання ""Іскандерів"" в Криму",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021404/,"Підрозділи Сил спеціальних опера																
20	Економіка,Росія почне повністю блокувати Telegram з 1 квітня – Baza,Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021405/,"Telegram-каналу ""База"" повідомив, що в Росії поч																
21	Економіка,"На КПП Польщі з Україною у мандрівника виявили гранату, людей евакуювали",Дата не вказана,https://www.pravda.com.ua/news/2026/02/17/8021400/,"На пункті пропуску в Долгоб																

pravda_news_20260217_123452

3.5. Програмний код, що забезпечує отримання результату:

```python
import requests
from bs4 import BeautifulSoup
import csv
import re
from datetime import datetime
from urllib.parse import urljoin


BASE_URL = "https://www.pravda.com.ua"
HEADERS = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36"
}


def clean_text(text: str) -> str:
    """Очищення тексту: прибирає зайві пробіли/переноси/табуляції."""
    if not text:
        return ""
    text = re.sub(r"\s+", " ", text)
    return text.strip()


def fetch_html(url: str) -> str | None:
    """Надсилання HTTP-запиту + Отримання HTML-документа + перевірка відповіді."""
    try:
        resp = requests.get(url, headers=HEADERS, timeout=12)
    except requests.RequestException:
        print("Вивести повідомлення про помилку: не вдалося виконати HTTP-запит.")
        return None
```

```python

    if resp.status_code != 200:
        print(
            f"Вивести повідомлення про помилку: сервер повернув статус {resp.status_code}.")
        return None

    return resp.text


def extract_article_text(article_url: str) -> str:
    """Витяг повного тексту зі сторінки новини (p-теги)."""
    html = fetch_html(article_url)
    if not html:
        return ""

    soup = BeautifulSoup(html, "html.parser")
    for tag in soup(["script", "style", "noscript"]):
        tag.decompose()

    paragraphs = soup.find_all("p")
    text = " ".join(clean_text(p.get_text(" ", strip=True))
                    for p in paragraphs)
    text = clean_text(text)

    # фільтрація від пустих сторінок
    if len(text) < 200:
        return ""

    return text


def parse_article(link_tag, section_name: str, url: str) -> dict:
    """
    Обробка кожної новини:
    - заголовок + URL беремо зі списку
    - дату пробуємо знайти поруч у DOM (time)
    - опис = перші 200 символів повного тексту
    """
    title = clean_text(link_tag.get_text(" ", strip=True)) or "Без заголовка"

    time_text = "Дата не вказана"
    parent = link_tag.parent
    if parent:
        time_tag = parent.find("time")
        if time_tag:
            time_text = clean_text(time_tag.get_text(" ", strip=True))

```

```python
    full_text = extract_article_text(url) if url else ""
    description = (full_text[:200] +
                   "...") if len(full_text) > 200 else full_text

    return {
        "section": section_name,
        "title": title,
        "time_text": time_text,
        "url": url,
        "description": description
    }


def is_good_link(full_url: str, link_text: str, section_url: str) -> bool:
    """Фільтр посилань: окремі правила для pravda.com.ua і life.pravda.com.ua."""
    if not full_url.startswith("http"):
        return False

    text = clean_text(link_text)
    if len(text) < 10:
        return False

    # відсіювання лишнього
    bad_parts = ["/tags/", "/search/", "/authors/", "#",
                 "facebook.com", "t.me", "twitter.com", "instagram.com"]
    if any(bp in full_url for bp in bad_parts):
        return False

    is_life = "life.pravda.com.ua" in section_url

    if not is_life:

        return ("/news/" in full_url) or ("/articles/" in full_url) or ("/columns/" in full_url)
    else:

        return "life.pravda.com.ua" in full_url


def parse_section(section_url: str, section_name: str, limit: int = 10) -> list:
    """
    Парсинг HTML → Пошук контейнерів/посилань → Цикл обробки кожної новини
    """
    print(f"\nЗавантаження розділу: {section_name}")

    html = fetch_html(section_url)
    if not html:
        return []

    soup = BeautifulSoup(html, "html.parser")
    links = soup.find_all("a", href=True)

    seen = set()
    picked = []
```

```python

    # Пошук посилань на новини
    for a in links:
        href = a.get("href", "").strip()
        if not href:
            continue

        if href.startswith("/"):
            full = urljoin(section_url, href)
        else:
            full = href

        if full.startswith("/"):
            full = urljoin(BASE_URL, full)

        if full in seen:
            continue

        if not is_good_link(full, a.get_text(" ", strip=True), section_url):
            continue

        seen.add(full)
        picked.append((a, full))

        if len(picked) >= limit:
            break

    news_list = []

    # тут відбувається обробка кожної новини
    for link_tag, url in picked:
        parsed = parse_article(link_tag, section_name, url)
        if parsed.get("description"):  # якщо вдалося витягнути хоча б якийсь текст
            news_list.append(parsed)

    print(f"Знайдено новин: {len(news_list)}")
    return news_list


def save_to_csv(data: list, filename: str) -> None:
    """Збереження у файл CSV (етап перед 'Кінець')."""
    with open(filename, "w", encoding="utf-8", newline="") as f:
        writer = csv.writer(f, quoting=csv.QUOTE_MINIMAL)
        writer.writerow(["Розділ", "Заголовок", "Дата", "Посилання", "Опис"])

        for item in data:
            writer.writerow([
                item.get("section", ""),
                item.get("title", ""),
                item.get("time_text", ""),
                item.get("url", ""),
                item.get("description", "")
            ])
```

```python
    print(f"Збережено у файл: {filename}")


def main():

    print("ПАРСИНГ PRAVDA.COM.UA")

    # Ініціалізація параметрів (список розділів)
    available_sections = [
        {"name": "Новини", "url": "https://www.pravda.com.ua/news/"},
        {"name": "Політика", "url": "https://www.pravda.com.ua/news/politics/"},
        {"name": "Економіка", "url": "https://www.pravda.com.ua/news/economics/"},
        {"name": "Європейська правда", "url": "https://www.eurointegration.com.ua/"},
        {"name": "Життя", "url": "https://life.pravda.com.ua/"},
        {"name": "Колонки", "url": "https://www.pravda.com.ua/columns/"},
    ]

    print("\nДоступні розділи:")
    for i, section in enumerate(available_sections, start=1):
        print(f"{i}. {section['name']}")

    # Вибір 3 розділів
    while True:
        try:
            choices = input(
                "\nВиберіть 3 розділи (через кому, наприклад 1,2,3): ")
            indices = [int(x.strip()) - 1 for x in choices.split(",")]

            if len(indices) != 3:
                raise ValueError("Потрібно обрати рівно 3 розділи.")

            selected_sections = [available_sections[i] for i in indices]
            break
        except (ValueError, IndexError):
            print("Неправильний ввід. Спробуйте ще раз.")

    print("\nОбрані розділи:")
    for s in selected_sections:
        print(f"• {s['name']}")

    all_news = []

    for section in selected_sections:
        news = parse_section(section["url"], section["name"], limit=10)
        all_news.extend(news)

    # Якщо новини нема то  повідомлення і завершення
    if not all_news:
        print("\nНовини не знайдені.")
        return

    print(f"\nВсього зібрано: {len(all_news)} новин")

    # Збереження у файл
    timestamp = datetime.now().strftime("%Y%m%d_%H%M%S")
    filename = f"pravda_news_{timestamp}.csv"
    save_to_csv(all_news, filename)

    print("\nГотово!")


if __name__ == "__main__":
    main()
```

IV. Висновки.

У ході виконання лабораторної роботи було розроблено програмну систему для автоматизованого отримання та обробки текстових даних природної мови з веб-ресурсу новинного сайту pravda.com.ua.

Було реалізовано алгоритм web-скрапінгу, який включає формування HTTP-запиту, отримання HTML-документа, його структурний аналіз та виділення інформаційних блоків новин. Для цього використано бібліотеки requests та BeautifulSoup.

У процесі роботи розроблено механізм очищення тексту від службових символів та надлишкових пробілів за допомогою регулярних виразів. Отримані дані структуровано у вигляді словникових об’єктів та збережено у форматі CSV для подальшого аналізу.

Побудована блок-схема алгоритму повністю відповідає програмній реалізації та відображає всі етапи обробки: від ініціалізації параметрів до збереження результатів у файл.

Репозиторій з кодом:
https://github.com/Pedroman17/AK_3/tree/main/code